STL Decomposition

산업시스템공학부 이지훈

Contents

1. 배경

2. 방법론

3. 결론

배경

소개

- STL은 "Seasonal and Trend decomposition using Loess(Loess를 사용한 계절성과 추세 분해)"의 약자
- R. B. Cleveland, Cleveland, McRae, & Terpenning (1990) 가 개발
- 데이터의 복잡한 구조를 시각적으로 분리하여 시계열의 본질적 특징을 파악하기 위해 개발

Journal of Official Statistics
Vol. 6. No. 1, 1990, pp. 3–73
© Statistics Sweden

STL: A Seasonal-Trend Decomposition Procedure Based on Loess

Robert B. Cleveland,[1] William S. Cleveland,[2] Jean E. McRae,[2] and Irma Terpenning[2]

배경

기술적 배경

- 전통적인 시계열 분해 방식의 한계 극복: 기존 방식은 이상치에 너무 민감하고, 시간이 흐름에 따라 변화하는 계절성 패턴을 유연하게 반영하지 못함

- 다양한 비즈니스 및 연구 지표 분석의 필요성: 여러 외부 요인에 의해 변동성이 큰 데이터를 정밀하게 분석해야 하는 요구가 증가

- 강건하고 유연한 도구의 필요: 데이터에 노이즈나 이상한 값이 있어도 안정적으로 추세를 추정하고, 월별/일별 등 다양한 주기성을 자유롭게 설정할 수 있는 자동화된 통계 도구로서 STL이 개발

- 최근에는 딥러닝의 효율을 높이는 필터로 데이터 정체 및 전처리에서 사용

배경

구분	전통적인 시계열 모델	STL 분해
사용자 난이도	파라미터 튜닝과 모델 설정에 깊은 전문 지식 필요	비교적 직관적인 파라미터 설정으로 전문적인 분석 가능
계절성 처리	제한적이거나 단일 주기 계절성 위주, 복잡한 다중 계절성 어려움	Loess(국소 회귀)를 사용하여 시간에 따라 변화하는 계절성을 유연하게 포착
이상치 및 결측치 대응	이상치와 결측치에 민감, 예측 정확도 저하 가능	강건(Robust) 옵션을 통해 이상치가 있어도 추세와 계절성을 안정적으로 추출
비즈니스 이벤트 반영	휴일이나 이벤트 반영이 어려움	발생한 데이터 내에서 이벤트가 전체 흐름에 얼마나 큰 충격을 주었는지 정밀하게 측정
실무 적용성	데이터 전처리 및 튜닝에 시간과 노력이 많이 소요, 통계적 지식 필요, 해석이 복잡할 수 있음	동성이 큰 데이터의 기초 구조를 파악하는 전처리 도구로 탁월

방법론

주요 구성 요소

- 추세: 데이터의 장기적인 방향성을 나타내는 추세 성분

  데이터의 장기적인 흐름을 잡아내기 위해 저주파 필터링을 거친 값

- 계절성: 일정한 주기로 반복되는 계절성 성분

  주기적으로 반복되는 패턴을 의미하며, STL은 시간에 따라 이 패턴이 변할 수 있다고 가정

- 잔차: 추세와 계절성으로 설명되지 않는 무작위 오차이자, 돌발 이벤트가 포함되는 영역

데이터 = 추세 + 계절성 + 잔차

$$Y_t = T_t + S_t + R_t$$

방법론

추세 성분 (Trend Component)

- 추세: 데이터의 장기적인 방향성을 나타내는 추세 성분
  데이터의 장기적인 흐름을 잡아내기 위해 저주파 필터링을 거친 값

- 실제 관측값에서 계절성을 제거한 상태에서, Loess 평활화 함수를 적용하여 단기적인 변동(노이즈)을 걸러낸 곡선

$$T_t = L(Y_t - S_t)$$

데이터 = 추세 + 계절성 + 잔차

방법론

계절성 성분 (Seasonal Component)

- 계절성: 일정한 주기로 반복되는 계절성 성분

  주기적으로 반복되는 패턴을 의미하며, STL은 시간에 따라 이 패턴이 변할 수 있다고 가정

관측값에서 추세를 뺀 나머지에서 주기성을 가진 성분만을 Loess로 추출. 이를 통해 매년 혹은 매주 반복되는 일정한 흐름을 계산

$$S_t = S(Y_t - T_t)$$

데이터 = 추세 + 계절성 + 잔차

방법론

잔차/나머지 성분 (Remainder Component)

- 잔차: 추세와 계절성으로 설명되지 않는 무작위 오차이자, 돌발 이벤트가 포함되는 영역

- 전체 관측값에서 우리가 찾아낸 추세와 계절성을 모두 뺀 값으로, 이 값이 특정 시점에 크다면 그 시점에 비즈니스 이벤트나 이상치가 발생했음을 의미

$$R_t = Y_t - T_t - S_t$$

데이터 = 추세 + 계절성 + 잔차

방법론

실습

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.seasonal import STL

# 1. 가상의 항공 수요 데이터 생성 (추세 + 계절성 + 노이즈)
np.random.seed(42)
t = np.arange(1, 121)  # 10년치 월별 데이터 (120개월)
trend = 0.5 * t        # 장기적인 상승 추세
seasonal = 10 * np.sin(2 * np.pi * t / 12)  # 12개월 주기 계절성
remainder = np.random.normal(0, 2, 120)     # 잔차 (노이즈)

# 실제 관측값 (Y = T + S + R)
y = trend + seasonal + remainder
data = pd.Series(y, index=pd.date_range("2016-01-01", periods=120, freq="M"))

# 2. STL 분해 적용
# period=12: 월별 데이터이므로 주기를 12로 설정
# robust=True: 이상치에 강건하게 대응하도록 설정
stl = STL(data, period=12, robust=True)
result = stl.fit()

# 3. 결과 시각화
plt.figure(figsize=(10, 8))
result.plot()
plt.show()

# 4. 분해된 성분 확인 (추세, 계절성, 잔차 수치 추출)
df_result = pd.concat([result.observed, result.trend, result.seasonal, result.resid], axis=1)
df_result.columns = ['Observed', 'Trend', 'Seasonal', 'Remainder']
print(df_result.head())
```

실습 환경: google colab

실습 데이터: 가상의 항공수요

라이브러리

- statsmodels (STL 클래스): 파이썬의 대표적인 통계 분석 라이브러리

방법론

실습 결론

	Observed	Trend	Seasonal	Remainder
2016-01-31	6.493428	2.269279	4.982318	-0.758169
2016-02-29	9.383725	2.551316	6.878926	-0.046517
2016-03-31	12.795377	2.832938	9.045217	0.917223
2016-04-30	13.706314	3.114763	10.346735	0.244815
2016-05-31	7.031693	3.397013	3.826907	-0.192227

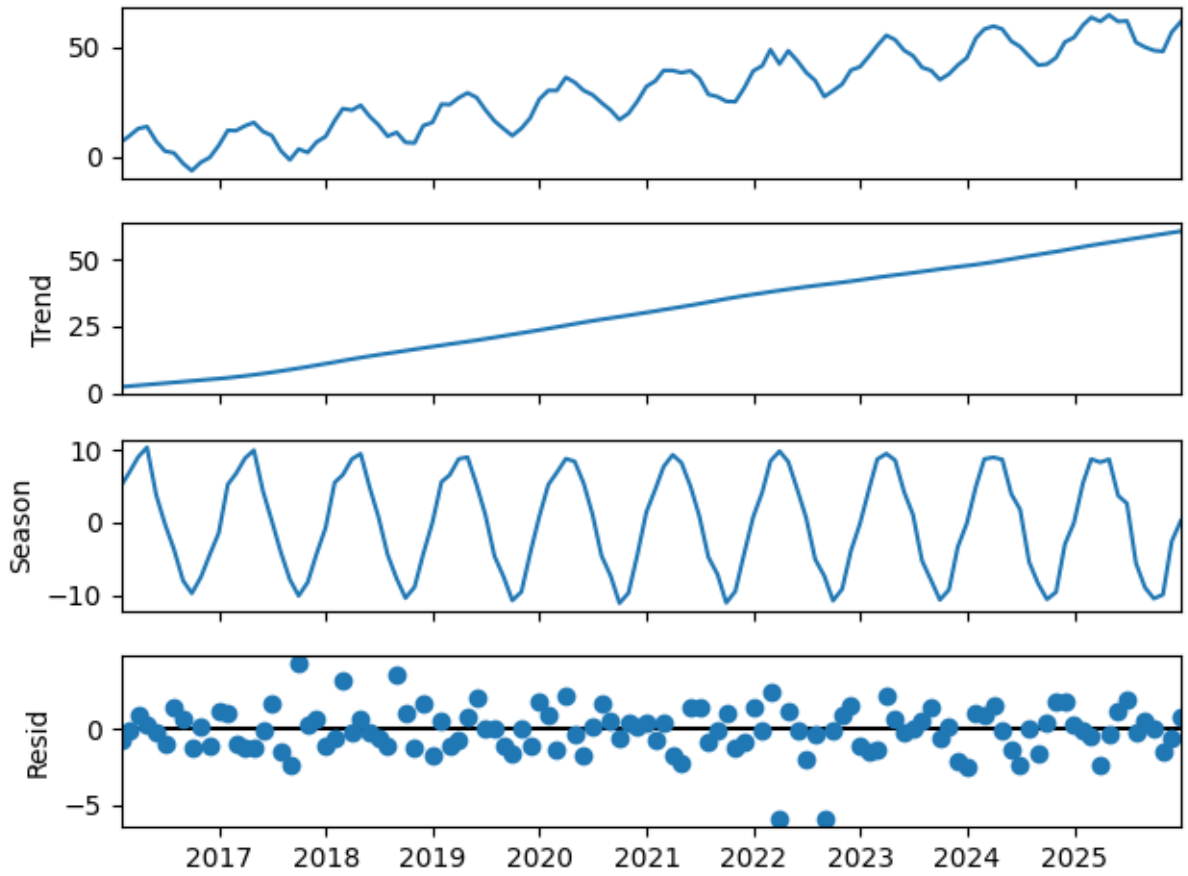

Observed (실제 관측값):추세, 계절성, 잔차가 모두 합쳐진 그래프. 우상향하면서도 주기적으로 출렁이는 복합적인 형태

Trend (추세):해석: 데이터가 장기적으로 어떤 방향으로 가고 있는지를 보여줌, 지속적으로 우상향 ->.이는 항공 시장의 장기적인 성장세나 수요 증가 흐름

Seasonal (계절성):해석: 1년(12개월) 단위로 반복되는 일정한 패턴, 매년 특정 시기에는 수요가 급증하고 특정 시기에는 급감하는 패턴이 매우 뚜렷
->STL은 이 패턴이 시간에 따라 미세하게 변하더라도 이를 유연하게 잡아낼 수 있음

Resid / Remainder (잔차):해석: 추세와 계절성으로 설명되지 않는 돌발 변수가 0을 중심으로 위아래로 흩어져 있음. 예시에는 2022년 하반기에 아래로 크게 튀는 지점이 보이는데, 실제 연구라면 이 시점에 '기상 악화'나 '정책 변화' 같은 특이 이벤트가 있었는지 분석해야 하는 핵심 구간

방법론

관련 논문

논문 제목	저자
실시간 도시철도 승・하차량 예측을 위한 STL 기법 적용 연구	우성종 외, 2024
STL을 이용한 우리나라 시계열의 계절조정	이긍희, 2021
STL 파일 모델로부터 유한 요소망 자동 생성	박정민 외, 207
시계열 분해 및 데이터 증강 기법 활용 건화물운임지수 예측	한민수 외, 2022
STL 분해 기반의 LSTM-GRU 하이브리드 모델을 이용한 전력 수요 예측	박준형 외, 2022
STL 시계열 분해를 활용한 기술 트렌드 및 유망 기술 탐색 모델	

- 하이브리드 인공지능 모델링, 시계열 분석 및 예측, 트헨드 분석 등에 사용

결론

STL 분해의 장점

- 극강의 유연성 -> 대부분의 시계열 모델은 '고정 계절성'을 사용하지만, STL은 국소회귀(Loess) 사용
- 이상치에 강함
- 어떤 데이터 주기에도 대응 가능 (계절성 주기를 자유롭게 조정 가능)
- 결측치 처리에 관대함 -> 데이터가 비어있어도 모델이 멈추지 않음
- 직관적인 해석과 제어

결론

STL 분해의 단점

- 덧셈 분해만 기본 지원 -> 시간이 지날수록 변동 폭이 커지는 데이터는 처리하지 못함
- 달력 변동 자동 처리 불가 (공휴일과 같은 특정 부분 자동 계산 하지 못함)
- 파라미터 튜닝의 필요성 (설정값이 많음)
- 예측 기능의 부재

결론

결론

- 데이터를 추세(Trend) + 계절성(Seasonal) + 잔차(Remainder) 세 가지로 쪼개는 기법
- 복잡한 시계열 데이터를 추세·계절성·잔차로 정교하게 분리하여, 노이즈에 휘둘리지 않고 데이터의 본질적 패턴을 찾아내는 핵심 분석 도구

항공/물류 수요 분석, 이상탐지, 딥러닝의 전처리, 트렌드 분석, 등